SQL - Funkcje okna (Window functions) Lab 1

Imiona i nazwiska: Marek Małek, Mateusz Lampert

Celem ćwiczenia jest przygotowanie środowiska pracy, wstępne zapoznanie się z działaniem funkcji okna (window functions) w SQL, analiza wydajności zapytań i porównanie z rozwiązaniami przy wykorzystaniu “tradycyjnych” konstrukcji SQL

Swoje odpowiedzi wpisuj w miejsca oznaczone jako:

Wyniki:

```
--  ...
```

Ważne/wymagane są komentarze.

Zamieść kod rozwiązania oraz zrzuty ekranu pokazujące wyniki, (dołącz kod rozwiązania w formie tekstowej/źródłowej)

Zwróć uwagę na formatowanie kodu

Oprogramowanie - co jest potrzebne?

Do wykonania ćwiczenia potrzebne jest następujące oprogramowanie:

- MS SQL Server - wersja 2019, 2022, 2025
- PostgreSQL - wersja 15/16/17/18
- SQLite
- Narzędzia do komunikacji z bazą danych
  - SSMS - Microsoft SQL Managment Studio
  - DtataGrip lub DBeaver
- Przykładowa baza Northwind
  - W wersji dla każdego z wymienionych serwerów

Oprogramowanie dostępne jest na przygotowanej maszynie wirtualnej

Dokumentacja/Literatura

- Kathi Kellenberger, Clayton Groom, Ed Pollack, Expert T-SQL Window Functions in SQL Server 2019, Apres 2019
- Itzik Ben-Gan, T-SQL Window Functions: For Data Analysis and Beyond, Microsoft 2020
- Kilka linków do materiałów które mogą być pomocne - https://learn.microsoft.com/en-us/sql/t-sql/queries/select-over-clause-transact-sql?view=sql-server-ver16
  - https://www.sqlservertutorial.net/sql-server-window-functions/
  - https://www.sqlshack.com/use-window-functions-sql-server/
  - https://www.postgresql.org/docs/current/tutorial-window.html
  - https://www.postgresqltutorial.com/postgresql-window-function/
  - https://www.sqlite.org/windowfunctions.html
  - https://www.sqlitetutorial.net/sqlite-window-functions/
- W razie potrzeby - opis Ikonek używanych w graficznej prezentacji planu zapytania w SSMS jest tutaj:
  - https://docs.microsoft.com/en-us/sql/relational-databases/showplan-logical-and-physical-operators-reference

Przygotowanie

Uruchom SSMS - Skonfiguruj połączenie z bazą Northwind na lokalnym serwerze MS SQL

Uruchom DataGrip (lub Dbeaver)

- Skonfiguruj połączenia z bazą Northwind3
  - na lokalnym serwerze MS SQL
  - na lokalnym serwerze PostgreSQL
  - z lokalną bazą SQLite

Zadanie 1 - obserwacja

Wykonaj i porównaj wyniki następujących poleceń.

```
select avg(unitprice) avgprice
from products p;
```

```sql
select avg(unitprice) over () as avgprice
from products p;

select categoryid, avg(unitprice) avgprice
from products p
group by categoryid

select avg(unitprice) over (partition by categoryid) as avgprice
from products p;
```

Jaka jest są podobieństwa, jakie różnice pomiędzy grupowaniem danych a działaniem funkcji okna?

Wyniki:

```
select avg(unitprice) avgprice
from products p;

=> jeden wiersz, globalna średnia równa ~28.834

===

select avg(unitprice) over () as avgprice
from products p;

=> 77 wierszy, globalna średnia równa ~28.834 "doklejona" do każdego wiersza (okno zdefiniowane jako wszystkie wiersze)

===

select categoryid, avg(unitprice) avgprice
from products p
group by categoryid;

=> 8 wierszy, dla każdego categoryid mamy średnią dla danej kategorii, oryginalne wiersze zostały zredukowane do agregatów

===

select avg(unitprice) over (partition by categoryid) as avgprice
from products p;

=> 77 wierszy, do każdego wiersza doklejona jest średnia z danej kategorii (categoryid)

===

select p.productid, p.ProductName, p.unitprice,
       (select avg(unitprice) from products) as avgprice
from products p
where productid < 10;

=> 9 wierszy, do każdego doklejona jest globalna średnia (bo mamy podzapytanie, w którym nie obowiązuje filtr productid < 10) równa ~28.834
```

```sql
select p.productid, p.ProductName, p.unitprice,
       avg(unitprice) over () as avgprice
from products p
where productid < 10;

=> 9 wierszy, do każdego doklejona jest średnia z tych 9. wierszy (filtr obowiązuje wewnątrz okna) równa ~ 31.372
```

Zadanie 2 - obserwacja

Wykonaj i porównaj wyniki następujących poleceń.

```sql
--1)

select p.productid, p.ProductName, p.unitprice,
       (select avg(unitprice) from products) as avgprice
from products p
where productid < 10

--2)
select p.productid, p.ProductName, p.unitprice,
       avg(unitprice) over () as avgprice
from products p
where productid < 10
```

Jaka jest różnica? Czego dotyczy warunek w każdym z przypadków?

Napisz polecenie równoważne

- 1. z wykorzystaniem funkcji okna.
- 2. z wykorzystaniem podzapytania

Wyniki:

Podobnie jak w zadanie 1. - w przypadku pierwszego zapytania średnia uwzględnia wszystkie rekordy (`avgprice` to wynik podzapytania, w którym warunek `where productid < 10` już nie obowiązuje), w przypadku drugiego zapytania warunek ten jest uwzględniany, a funkcja okna bierze średnią wyłącznie z tych odfiltrowanych 9. wierszy. W obu przypadkach wartości średniej są doklejane do wszystkich wierszy.

```sql
--1-with-window)
select productid, productname, unitprice, avgprice
from (
    select p.productid, p.productname, p.unitprice,
           avg(unitprice) over () as avgprice
    from products p
) sub
where productid < 10;

--2-with-subquery)
select p.productid, p.ProductName, p.unitprice,
       (select avg(unitprice) from products where productid < 10)
from products p
where productid < 10
```

Zadanie 3

Baza: Northwind, tabela: products

Napisz polecenie, które zwraca: id produktu, nazwę produktu, cenę produktu, średnią cenę wszystkich produktów.

Napisz polecenie z wykorzystaniem z wykorzystaniem podzapytania, join'a oraz funkcji okna. Porównaj czasy oraz plany wykonania zapytań.

Przetestuj działanie w różnych SZBD (MS SQL Server, PostgreSql, SQLite)

W SSMS włącz dwie opcje: Include Actual Execution Plan oraz Include Live Query Statistics

W DataGrip użyj opcji Explain Plan/Explain Analyze

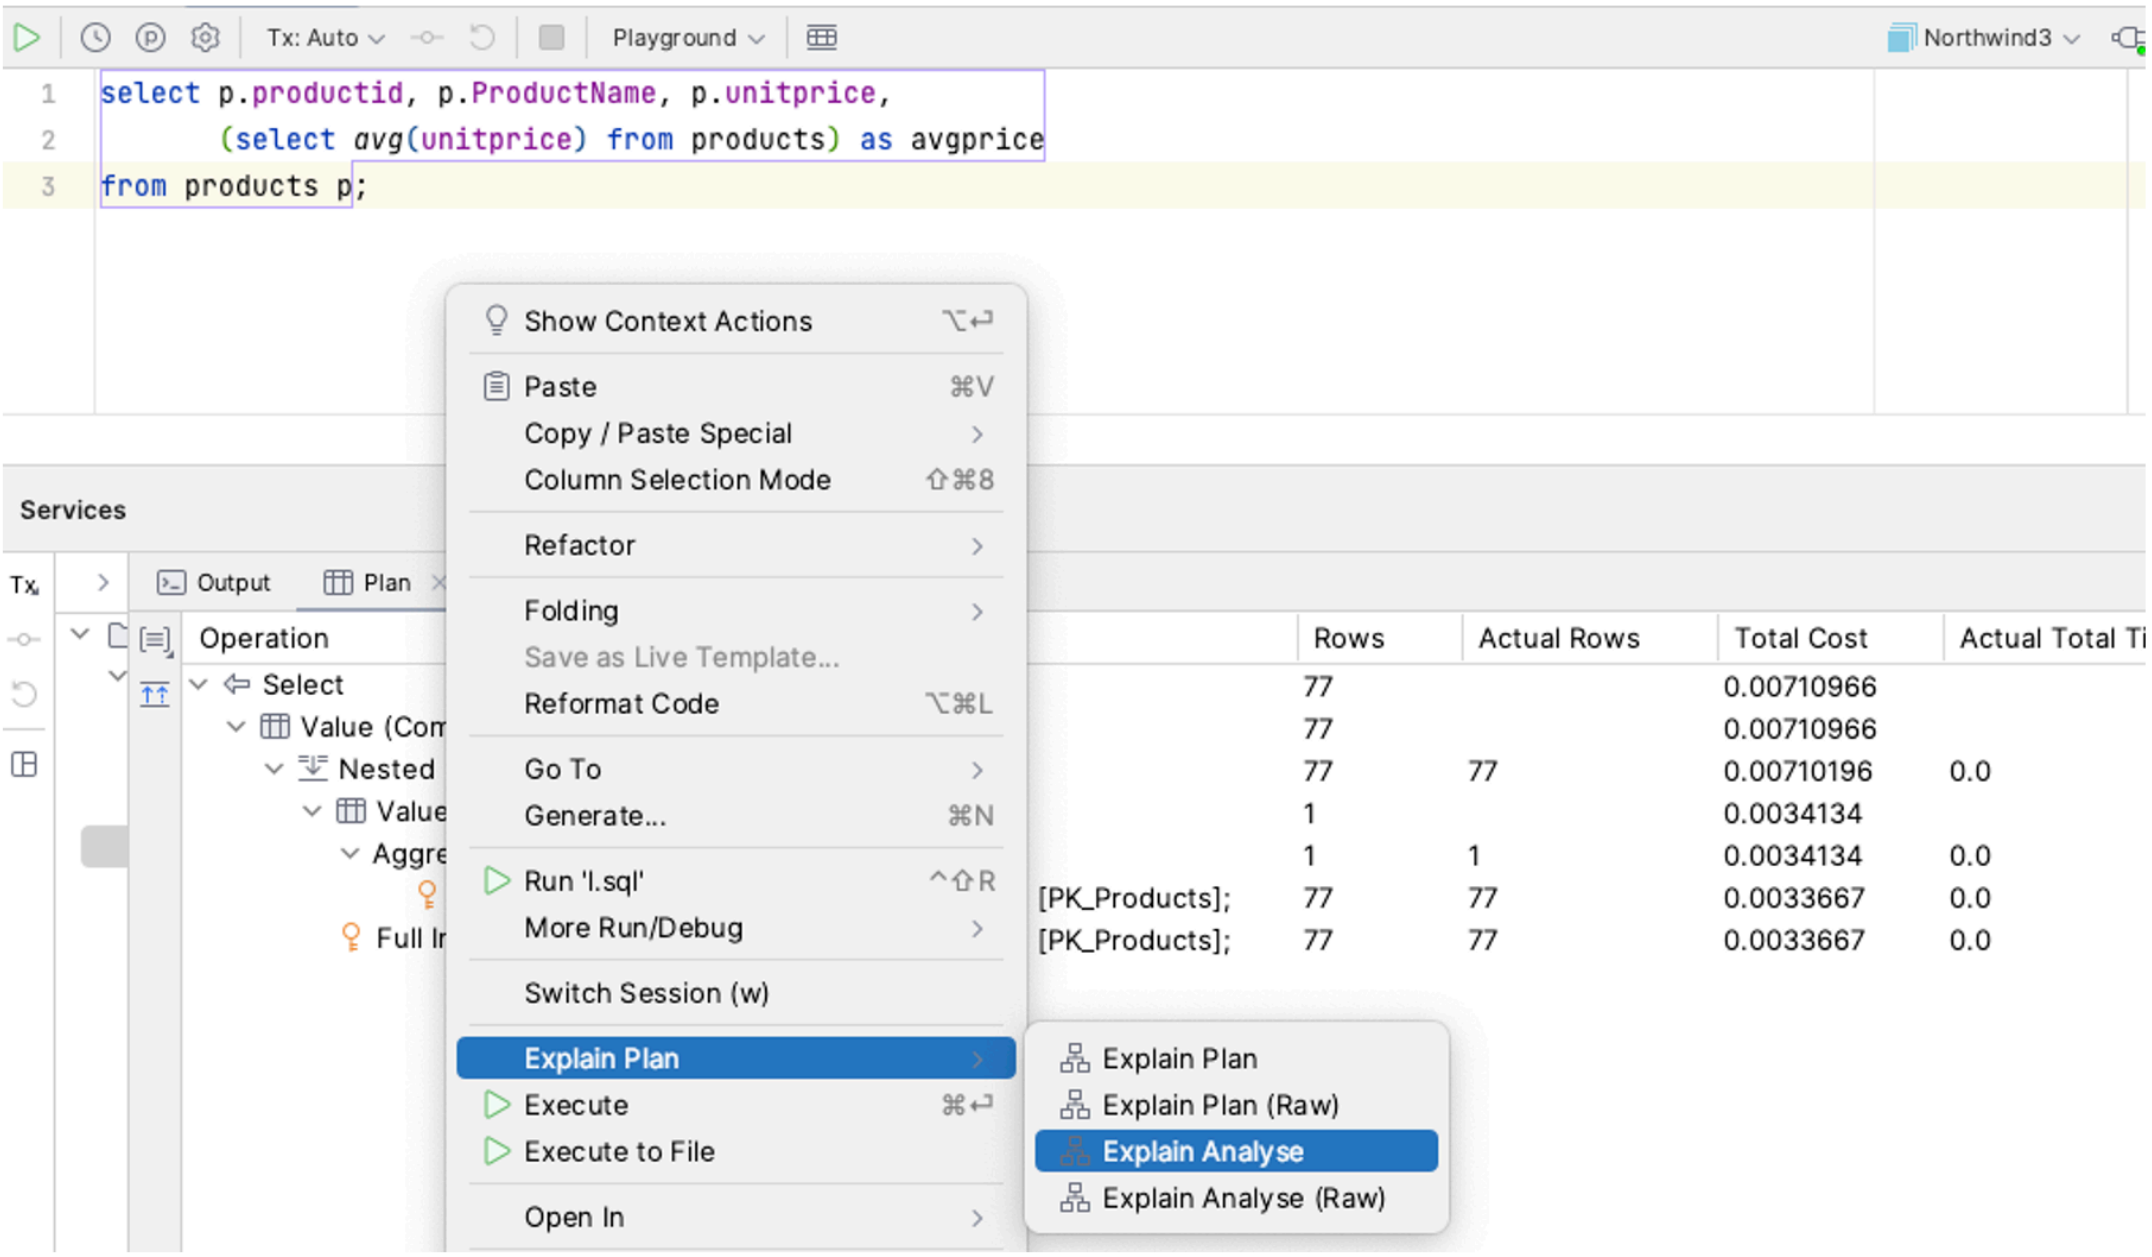

Wizualizacja 1: w:700

Wyniki:

Różnice w czasie wykonania zapytania są marginalne ze względu na rozmiar tabeli `products` (77 wierszy) - w rezultacie nie ma sensu porównywanie czasu wykonania zapytań.

```
--subquery
select p.productid, p.productname, p.unitprice,
       (select avg(unitprice) from products) as avgprice
from products p;
```

Postgres:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time	Startup Cost	Actual Startup Time
Select							
Full Scan (Seq Scan)	table: products;	77	77.0	3.75	2.841	1.97	2.836
Aggregate		1	1.0	1.97	0.11	1.96	0.109
Full Scan (Seq S	table: products;	77	77.0	1.77	0.022	0.0	0.019

MSSQL:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time
Select		77		0.00859114	
Value (Compute Scalar)		77		0.00859114	
Nested Loops (Inner Join - I		77	77	0.00858344	0.0
Value (Compute Scalar)		1		0.00415414	
Aggregate (Aggregate - S		1	1	0.00415414	0.0
Full Index Scan (Cl	table: [dbo].[products]; index: [pk_products];	77	77	0.00410744	0.0
Full Index Scan (Clustere	table: [dbo].[products]; index: [pk_products];	77	77	0.00410744	0.0

SQLite:

Operation	Params	Raw Desc
Select		
Full Scan	table: p;	SCAN p
Subquery	Scalar;	SCALAR SUBQUERY 1
Full Scan	table: products;	SCAN products

```sql
--join
select p.productid, p.productname, p.unitprice, sub.avgprice
from products p
cross join (
    select avg(unitprice) as avgprice
    from products
) sub;
```

Postgres:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time	Startup Cost	Actual Startup Time
Select							
Nested Loops (Nested		77	77.0	4.51	0.188	1.96	0.163
Aggregate		1	1.0	1.97	0.054	1.96	0.054
Full Scan (Seq S	table: products;	77	77.0	1.77	0.032	0.0	0.024
Full Scan (Seq Sca	table: products;	77	77.0	1.77	0.014	0.0	0.006

MSSQL:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time
Select		77		0.00858344	
Nested Loops (Inner Join - N		77	77	0.00858344	0.0
Value (Compute Scalar)		1		0.00415414	
Aggregate (Aggregate - S		1	1	0.00415414	0.0
Full Index Scan (Clu	table: [dbo].[products]; index: [pk_products];	77	77	0.00410744	0.0
Full Index Scan (Clustere	table: [dbo].[products]; index: [pk_products];	77	77	0.00410744	0.0

SQLite:

Operation	Params	Raw Desc
Select		
Operation (MATERIALIZE)		MATERIALIZE sub
Full Scan	table: products;	SCAN products
Full Scan	table: p;	SCAN p
Full Scan	table: sub;	SCAN sub

```sql
--window function
select p.productid, p.productname, p.unitprice,
       avg(p.unitprice) over () as avgprice
from products p;
```

Postgres:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time	Startup Cost	Actual Startup Time
⇦ Select							
Transformation (Windo		77	77.0	2.73	0.35	2.7	0.33
Full Scan (Seq S	table: products;	77	77.0	1.77	0.234	0.0	0.226

MSSQL:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time
⇦ Select		77		0.0055688	
Nested Loops (Inner Join - Nested Loops)		77	77	0.0055688	1.0
Temporary (Lazy Spool - Table Spool)		1	2	0.00439971	0.0
Transformation (Segment)		77	77	0.00425358	0.0
Full Index Scan (Clustered Index Scan)	table: [dbo].[products]; index: [pk_products];	77	77	0.00410744	0.0
Nested Loops (Inner Join - Nested Loops)		77	77	2.92272E-5	0.0
Value (Compute Scalar)		1		1.6075E-5	
Aggregate (Aggregate - Stream Aggregate)		1	1	1.46136E-5	0.0
Temporary (Lazy Spool - Table Spool)		77	77	0.0	0.0
Temporary (Lazy Spool - Table Spool)		77	77	0.0	0.0

SQLite:

Operation	Params	Raw Desc
⇦ Select		
Operation (CO-ROUTINE)		CO-ROUTINE (subquery-2)
Full Scan	table: p;	SCAN p
Full Scan	table: (subquery-2);	SCAN (subquery-2)

Zadanie 4

Baza: Northwind, tabela products

Napisz polecenie, które zwraca: id produktu, nazwę produktu, cenę produktu, średnią cenę produktów w kategorii, do której należy dany produkt. Wyświetl tylko pozycje (produkty) których cena jest większa niż średnia cena.

Napisz polecenie z wykorzystaniem podzapytania, join'a oraz funkcji okna. Porównaj zapytania. Porównaj czasy oraz plany wykonania zapytań.

Przetestuj działanie w różnych SZBD (MS SQL Server, PostgreSql, SQLite)

Wyniki: W MSSQL plan wykonania jest dostosowany przez optymalizator i podmieniony na najbardziej optymalny (`totalTime` 0.0). W przypadku Postgresql i SQLite plan wykonania jest zgodny z napisanym zapytaniem.

```
--subquery
select p1.ProductID, p1.ProductName, p1.UnitPrice, (
    select avg(p2.unitprice)
    from products p2
    where p1.categoryid = p2.categoryid
) as AvgCategoryPrice
from Products p1
where p1.UnitPrice > (select avg(p3.UnitPrice) from Products p3 where p1.CategoryID = p3.CategoryID)
order by p1.ProductID;
```

Postgres:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time	Startup Cost	Actual Startup Time
Select							
Sort		26	27.0	208.64	2.401	208.57	2.396
Full Scan (Seq Scan)	table: products;	26	27.0	207.96	2.351	0.0	0.241
Aggregate		1	1.0	2.0	0.021	1.99	0.021
Full Scan (Seq Scan)	table: products;	10	10.19	1.96	0.018	0.0	0.005
Aggregate		1	1.0	2.0	0.021	1.99	0.021
Full Scan (Seq Scan)	table: products;	10	10.53	1.96	0.017	0.0	0.005

MSSQL:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time
Select		77		0.0500672	
Value (Compute Scalar)		77		0.0500672	
Nested Loops (Left Outer Join - Nested Loops)		77	27	0.0500595	1.0
Sort		77	27	0.0298979	1.0
Nested Loops (Inner Join - Nested Loops)		77	27	0.0177838	0.0
Temporary (Lazy Spool - Table Spool)		8	9	0.0165636	0.0
Transformation (Segment)		77	77	0.016411	0.0
Sort		77	77	0.0162585	0.0
Full Index Scan (Clustered Index Scan)	table: [dbo].[products]; index: [pk_products];	77	77	0.00410744	0.0
Nested Loops (Inner Join - Nested Loops)		9.625	27	3.05068E-5	0.0
Value (Compute Scalar)		1		1.67787E-5	
Aggregate (Aggregate - Stream Aggregate)		1	8	1.52534E-5	0.0
Temporary (Lazy Spool - Table Spool)		9.625	77	0.0	0.0
Temporary (Lazy Spool - Table Spool)		9.625	77	0.0	0.0
Value (Compute Scalar)		1		0.0198397	
Aggregate (Aggregate - Stream Aggregate)		1	27	0.0198397	0.0
Full Index Scan (Clustered Index Scan)	table: [dbo].[products]; index: [pk_products];	9.625	275	0.0165106	0.0

SQLite:

Operation	Params	Raw Desc
Select		
Full Scan	table: p1;	SCAN p1
Subquery	Scalar; Correlated;	CORRELATED SCALAR SUBQUERY 2
Index Scan	table: p3; index: CategoryID;	SEARCH p3 USING INDEX CategoryID (CategoryID=?)
Subquery	Scalar; Correlated;	CORRELATED SCALAR SUBQUERY 1
Index Scan	table: p2; index: CategoryID;	SEARCH p2 USING INDEX CategoryID (CategoryID=?)

```sql
--join
with t as (
    select CategoryID, avg(UnitPrice) as AvgPrice from Products
    group by CategoryID
)
select p.ProductID, p.ProductName, p.UnitPrice, t.AvgPrice from Products p
join t on p.CategoryID = t.CategoryID
where p.UnitPrice > t.AvgPrice
order by p.ProductID;
```

Postgres:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time	Startup Cost	Actual Startup Time	Raw Desc
Select								Planning Time = 0.1...
Sort		26	27	5.12	0.059	5.06	0.057	Parallel Aware = fals...
Hash Join		26	27	4.45	0.052	2.44	0.039	Parent Relationship...
Full Scan (Seq Scan)	table: products;	77	77	1.77	0.011	0.0	0.008	Parent Relationship...
Transformation (Hash)		8	8	2.33	0.026	2.33	0.025	Parent Relationship...
Access (Subquery Scan)		8	8	2.33	0.024	2.15	0.022	Parent Relationship...
Aggregate		8	8	2.25	0.023	2.15	0.022	Strategy = Hashed;...
Full Scan (Seq Scan)	table: products;	77	77	1.77	0.005	0.0	0.001	Parent Relationship...

MSSQL:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time	Raw Desc
Select		77		0.0298979		CardinalityEstimati...
Sort		77	27	0.0298979	0.0	AvgRowSize = 71;E...
Nested Loops (Inner Join - Nested Loops)		77	27	0.0177838	0.0	AvgRowSize = 71;E...
Temporary (Lazy Spool - Table Spool)		8	9	0.0165636	0.0	AvgRowSize = 67;E...
Transformation (Segment)		77	77	0.016411	0.0	AvgRowSize = 67;E...
Sort		77	77	0.0162585	0.0	AvgRowSize = 67;E...
Full Index Scan (Clustered Index Scan)	table: [dbo].[products]; index: [pk_products];	77	77	0.00410744	0.0	AvgRowSize = 67;E...
Nested Loops (Inner Join - Nested Loops)		9.625	27	3.05068E-5	0.0	AvgRowSize = 67;E...
Value (Compute Scalar)		1		1.67787E-5		AvgRowSize = 67;E...
Aggregate (Aggregate - Stream Aggregate)		1	8	1.52534E-5	0.0	AvgRowSize = 67;E...
Temporary (Lazy Spool - Table Spool)		9.625	77	0.0	0.0	AvgRowSize = 67;E...
Temporary (Lazy Spool - Table Spool)		9.625	77	0.0	0.0	AvgRowSize = 67;E...

SQLite:

Operation	Params	Raw Desc
Select		
Operation (CO-ROUTINE)		CO-ROUTINE t
Index Scan	table: Products; index: CategoryID;	SCAN Products USING INDEX CategoryID
Full Scan	table: t;	SCAN t
Index Scan	table: p; index: CategoryID;	SEARCH p USING INDEX CategoryID (CategoryID=?)
Order By		USE TEMP B-TREE FOR ORDER BY

```sql
--window function
with t as (
    select p.ProductID, p.ProductName, p.UnitPrice, avg(p.UnitPrice) over(partition by p.CategoryID) as AvgPrice from Products p
)
select ProductID, ProductName, UnitPrice, AvgPrice from t
where UnitPrice > AvgPrice
order by ProductID;
```

Postgres:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time	Startup Cost	Actual Startup Time	Raw Desc
Select								Planning Time = 0.07;Trigg...
Sort		26	27	156.64	0.357	156.57	0.356	Parallel Aware = false;Asyn...
Full Scan (Seq Scan)	table: products;	26	27	155.96	0.351	0.0	0.051	Parent Relationship = Oute...
Aggregate		1	1	2.0	0.004	1.99	0.004	Strategy = Plain;Partial Mo...
Full Scan (Seq Sc	table: products;	10	11	1.96	0.003	0.0	0.001	Parent Relationship = Oute...

MSSQL:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time	Raw Desc
Select		23.1		0.0293084		CardinalityEstimationModelVersion = 160;Query...
Sort		23.1	27	0.0293084	0.0	AvgRowSize = 71;EstimateCPU = 0.000263308;...
Filter		23.1	27	0.0177838	0.0	AvgRowSize = 71;EstimateCPU = 3.696e-05;Est...
Nested Loops (Inner Join - Nested Loops)		77	77	0.0177469	0.0	AvgRowSize = 71;EstimateCPU = 0.00117451;Es...
Temporary (Lazy Spool - Table Spool)		8	9	0.0165266	0.0	AvgRowSize = 67;EstimateCPU = 0;EstimateIO ...
Transformation (Segment)		77	77	0.0163741	0.0	AvgRowSize = 67;EstimateCPU = 0.000152534;...
Sort		77	77	0.0162215	0.0	AvgRowSize = 67;EstimateCPU = 0.000852833...
Full Index Scan (Clustered Index Scan)	table: [dbo].[products]; index: [pk_products];	77	77	0.00410744	0.0	AvgRowSize = 67;EstimateCPU = 0.0002417;Es...
Nested Loops (Inner Join - Nested Loops)		9.625	77	3.05068E-5	0.0	AvgRowSize = 67;EstimateCPU = 1.52534e-05;...
Value (Compute Scalar)		1		1.67787E-5		AvgRowSize = 67;EstimateCPU = 1.52534e-06;...
Aggregate (Aggregate - Stream Aggregate)		1	8	1.52534E-5	0.0	AvgRowSize = 67;EstimateCPU = 1.52534e-05;...
Temporary (Lazy Spool - Table Spool)		9.625	77	0.0	0.0	AvgRowSize = 67;EstimateCPU = 0;EstimateIO ...
Temporary (Lazy Spool - Table Spool)		9.625	77	0.0	0.0	AvgRowSize = 67;EstimateCPU = 0;EstimateIO ...

SQLite:

Operation	Params	Raw Desc
Select		
Operation (CO-ROUTINE)		CO-ROUTINE t
Operation (CO-ROUTINE)		CO-ROUTINE (subquery-3)
Index Scan	table: p; index: CategoryID;	SCAN p USING INDEX CategoryID
Full Scan	table: (subquery-3);	SCAN (subquery-3)
Full Scan	table: t;	SCAN t
Order By		USE TEMP B-TREE FOR ORDER BY

Zadanie 5

Oryginalna baza Northwind jest bardzo mała. Warto zaobserwować działanie na nieco większym zbiorze danych.

Baza Northwind3 zawiera dodatkową tabelę product_history

- 2,2 mln wierszy

Bazę Northwind3 można pobrać z moodle (zakładka - Backupy baz danych)

Można też wygenerować tabelę product_history przy pomocy skryptu

Skrypt dla SQL Srerver

Stwórz tabelę o następującej strukturze:

```sql
create table product_history(
   id int identity(1,1) not null,
   productid int,
   productname varchar(40) not null,
```

```
   supplierid int null,
   categoryid int null,
   quantityperunit varchar(20) null,
   unitprice decimal(10,2) null,
   quantity int,
   value decimal(10,2),
   date date,
 constraint pk_product_history primary key clustered
    (id asc )
)
```

Wygeneruj przykładowe dane:

Dla 30000 iteracji, tabela będzie zawierała nieco ponad 2mln wierszy (dostostu ograniczenie do możliwości swojego komputera)

Skrypt dla SQL Srerver

```
declare @i int
set @i = 1
while @i <= 30000
begin
    insert product_history
    select productid, ProductName, SupplierID, CategoryID,
         QuantityPerUnit,round(RAND()*unitprice + 10,2),
         cast(RAND() * productid + 10 as int), 0,
         dateadd(day, @i, '1940-01-01')
    from products
    set @i = @i + 1;
end;

update product_history
set value = unitprice * quantity
where 1=1;
```

Skrypt dla Postgresql

```
create table product_history(
   id int generated always as identity not null
       constraint pkproduct_history
            primary key,
   productid int,
   productname varchar(40) not null,
   supplierid int null,
   categoryid int null,
   quantityperunit varchar(20) null,
   unitprice decimal(10,2) null,
   quantity int,
   value decimal(10,2),
   date date
);
```

Wygeneruj przykładowe dane:

Skrypt dla Postgresql

```
do $$
begin
  for cnt in 1..30000 loop
    insert into product_history(productid, productname, supplierid,
           categoryid, quantityperunit,
           unitprice, quantity, value, date)
    select productid, productname, supplierid, categoryid,
           quantityperunit,
           round((random()*unitprice + 10)::numeric,2),
           cast(random() * productid + 10 as int), 0,
           cast('1940-01-01' as date) + cnt
    from products;
  end loop;
end; $$;

update product_history
set value = unitprice * quantity
where 1=1;
```

Wykonaj polecenia: `select count(*) from product_history`, potwierdzające wykonanie zadania

Wyniki:

```
select count(*) from product_history;
```

Postgres:

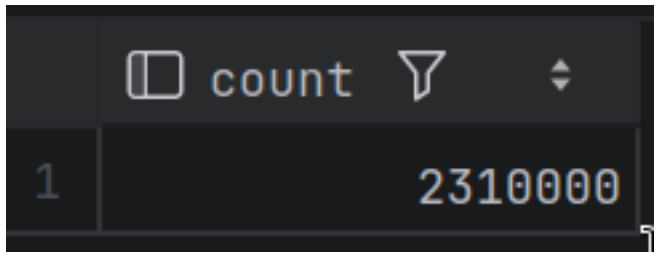

Wizualizacja 2: alt text

MSSQL:

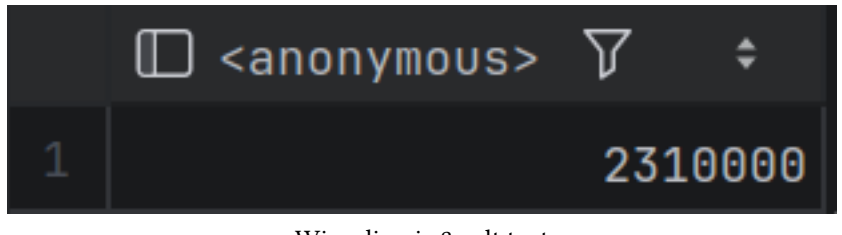

Wizualizacja 3: alt text

SQLite:

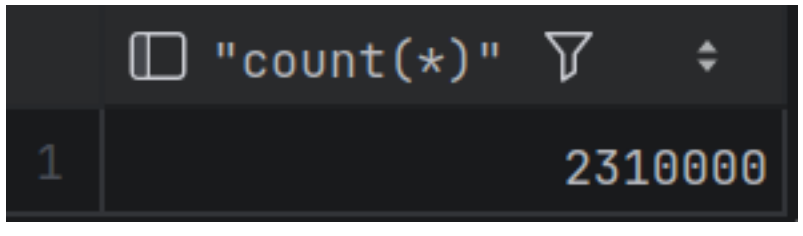

Wizualizacja 4: alt text

Zadanie 6

Baza: Northwind, tabela product_history

Napisz polecenie, które zwraca: id pozycji, id produktu, nazwę produktu, id_kategorii, cenę produktu, średnią cenę produktów w kategorii do której należy dany produkt. Wyświetl tylko pozycje (produkty) których cena jest większa niż średnia cena.

W przypadku długiego czasu wykonania ogranicz zbiór wynikowy do kilkuset/kilku tysięcy wierszy pomocna może być konstrukcja `with`

```
with t as (

....
)
select * from t
where id between ....
```

Napisz polecenie z wykorzystaniem podzapytania, join'a oraz funkcji okna. Porównaj zapytania. Porównaj czasy oraz plany wykonania zapytań.

Przetestuj działanie w różnych SZBD (MS SQL Server, PostgreSql, SQLite)

> Wyniki: Z podzapytaniem tylko MSSQL poradził sobie w skończonym czasie (457ms, 45ms dla ograniczonego zbioru), prawdopodobnie przez paralelizm. Postgresql i SQLite wypadly znacznie gorzej ~1 minuta na ograniczonym zbiorze, a dla pełnego zbioru zapytanie nie zostało ukończone w rozsądnym czasie. Przy joinie wyniki wyniosły odpowiednio MSSQL 458ms, Postgresql 1s, SQLite 1s. Przy funkcji okna MSSQL znów był najszybszy ~500ms, Postgresql 1.6s, SQLite 2s. DataGrip wskazał, że w przypadku MSSQL warto dodać indeks na kolumnie `categoryid` w tabeli `product_history`.

```
--subquery
select p1.id, p1.productid, p1.productname, p1.categoryid, p1.unitprice, (
    select avg(p2.unitprice)
    from product_history p2
    where p1.categoryid = p2.categoryid
) as AvgCategoryPrice
from product_history p1
where p1.unitprice > (
    select avg(p3.unitprice)
    from product_history p3
    where p1.categoryid = p3.categoryid
)
order by p1.productid;
```

MSSQL:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time
Select		2.31E+6		104.028	
Transformation (Gather Streams - Parallelism)		2.31E+6	776966	104.028	192.0
Sort		2.31E+6	776966	87.6585	342.0
Value (Compute Scalar)		2.31E+6	776966	59.7713	0.0
Hash Join (Right Outer Join - Hash Match)		2.31E+6	776966	59.7655	2.0
Value (Compute Scalar)		8	8	19.764	0.0
Aggregate (Aggregate - Hash Match)		8	8	19.764	5.0
Full Index Scan (Clustered Index Scan)	table: [dbo].[product_history]; index: [pk_product_history];	2.31E+6	2310000	19.3517	18.0
Hash Join (Inner Join - Hash Match)		2.31E+6	776966	39.5587	6.0
Value (Compute Scalar)		8	8	19.764	0.0
Aggregate (Aggregate - Hash Match)		8	8	19.764	7.0
Full Index Scan (Clustered Index Scan)	table: [dbo].[product_history]; index: [pk_product_history];	2.31E+6	2310000	19.3517	28.0
Full Index Scan (Clustered Index Scan)	table: [dbo].[product_history]; index: [pk_product_history];	2.31E+6	2310000	19.3517	31.0

```
-- subquery (reduced)
with t as (
    select p1.id, p1.productid, p1.productname, p1.categoryid, p1.unitprice, (
        select avg(p2.unitprice)
        from product_history p2
        where p1.categoryid = p2.categoryid
    ) as AvgCategoryPrice
    from product_history p1
    where p1.unitprice > (
        select avg(p3.unitprice)
        from product_history p3
```

```
        where p1.categoryid = p3.categoryid
    )
)
select *
from t
where t.id between 1000 and 1500
order by t.productid;
```

Postgres:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time	Startup Cost	Actual Startup Time
Select							
Sort		186	165.0	6.570569636E7	82737.22	6.57056959E7	82737.214
Index Scan	table: product_history; index: pkproduct_history;	186	165.0	6.570568888E7	82736.865	0.43	1127.466
Aggregate		1	1.0	88432.89	121.386	88432.88	121.386
Full Scan (S	table: product_history;	288750	308181.82	87711.0	106.859	0.0	0.001
Aggregate		1	1.0	88432.89	124.977	88432.88	124.977
Full Scan (S	table: product_history;	288750	316287.43	87711.0	109.942	0.0	0.002

SQLite:

Operation	Params	Raw Desc
Select		
Index Scan	table: p1;	SEARCH p1 USING INTEGER PRIMARY KEY (rowid>? AND rowid<?)
Subquery	Scalar; Correlated;	CORRELATED SCALAR SUBQUERY 1
Full Scan	table: p2;	SCAN p2
Order By		USE TEMP B-TREE FOR ORDER BY

```sql
--join
with t as (
    select categoryid, avg(unitprice) as avgprice
    from product_history
    group by categoryid
)
select p.id, p.productid, p.productname, p.unitprice, p.categoryid, t.avgprice
from product_history p
join t on p.categoryid = t.categoryid
where p.unitprice > t.avgprice
order by p.productid;
```

Postgres:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time	Startup Cost	Actual Startup Time	Raw Desc
Select								Planning Time = 0....
Unknown (Gather Merge)		641666	773614	282293.57	676.807	207427.31	606.163	Parallel Aware = fal...
Sort		320833	257871	207229.37	610.552	206427.28	596.305	Parent Relationshi...
Hash Join		320833	257871	165020.26	558.933	93486.28	417.849	Parent Relationshi...
Full Scan (Seq Scan)	table: product_history;	962500	770000	68461.0	47.579	0.0	0.012	Parent Relationshi...
Transformation (Hash)		8	8	93486.18	417.357	93486.18	417.355	Parent Relationshi...
Access (Subquery Sc		8	8	93486.18	417.351	93486.0	417.348	Parent Relationshi...
Aggregate		8	8	93486.1	417.344	93486.0	417.341	Strategy = Hashed...
Full Scan (Seq	table: product_history;	2310000	2310000	81936.0	167.11	0.0	0.004	Parent Relationshi...

MSSQL:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time	Raw Desc
Select ⚠		2.31E+6		57.9443		BatchModeOnRowSto...
Transformation (Gather Streams - Parallelism)		2.31E+6	775336	57.9443	80.0	AvgRowSize = 61;Esti...
Sort		2.31E+6	775336	47.2966	152.0	AvgRowSize = 61;Esti...
Hash Join (Inner Join - Hash Match)		2.31E+6	775336	44.4944	10.0	AvgRowSize = 61;Esti...
Value (Compute Scalar)		8	8	22.2035	0.0	AvgRowSize = 28;Esti...
Aggregate (Aggregate - Hash Match)		8	8	22.2035	6.0	AvgRowSize = 28;Esti...
Full Index Scan (Clustered Index Scan)	table: [dbo].[product_history]; index: [pk_product_history];	2.31E+6	2310000	21.98	17.0	AvgRowSize = 20;Esti...
Full Index Scan (Clustered Index Scan)	table: [dbo].[product_history]; index: [pk_product_history];	2.31E+6	2310000	21.98	28.0	AvgRowSize = 48;Esti...

SQLite:

Operation	Params	Raw Desc
Select		
Operation (CO-ROUTINE)		CO-ROUTINE t
Full Scan	table: product_history;	SCAN product_history
Group By		USE TEMP B-TREE FOR GROUP BY
Full Scan	table: p;	SCAN p
Unknown		BLOOM FILTER ON t (categoryid=?)
Index Scan	table: t; index: (categoryid=?);	SEARCH t USING AUTOMATIC COVERING INDEX (categoryid=?)
Order By		USE TEMP B-TREE FOR ORDER BY

```sql
--window function
with t as (
    select p.id, p.productid, p.productname, p.unitprice, p.categoryid, avg(p.unitprice) over(partition by p.categoryid) as avgprice
    from product_history p
)
select id, productid, productname, unitprice, categoryid, avgprice
from t
where unitprice > avgprice
order by productid;
```

Postgres:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time	Startup Cost	Actual Startup Time	Raw Desc
Select								Planning Time = 0....
Sort		770000	773614	641054.6	1551.254	639129.6	1516.452	Parallel Aware = fal...
Access (Subquery Scan)		770000	773614	505940.78	1365.618	436640.78	697.522	Parent Relationship...
Transformation (Window/		2310000	2310000	477065.78	1260.429	436640.78	697.515	Parent Relationship...
Sort		2310000	2310000	442415.78	740.655	436640.78	622.099	Parent Relationship...
Full Scan (Seq S	table: product_history;	2310000	2310000	81936.0	208.326	0.0	40.552	Parent Relationship...

MSSQL:

Operation	Params	Rows	Actual Rows	Total Cost	Actual Total Time	Raw Desc
Select		693000		28.9977		BatchModeOn...
Transformation (Gather Streams - Parallelism)		693000	775336	28.9977	109.0	AvgRowSize = ...
Sort		693000	775336	25.7835	158.0	AvgRowSize = ...
Filter		693000	775336	25.0115	1.0	AvgRowSize = ...
Value (Compute Scalar)		2.31E+6	2310000	24.8729	17.0	AvgRowSize = ...
Unknown (Window Aggregate)		2.31E+6	2310000	24.8729	9.0	AvgRowSize = ...
Sort		2.31E+6	2310000	24.7823	31.0	AvgRowSize = ...
Full Index Scan (Clustered Index Scan)	table: [dbo].[product_history]; index: [pk_product_history];	2.31E+6	2310000	21.98	32.0	AvgRowSize = ...

SQLite:

Operation	Params	Raw Desc
Select		
Operation (CO-ROUTINE)		CO-ROUTINE t
Operation (CO-ROUTINE)		CO-ROUTINE (subquery-3)
Full Scan	table: p;	SCAN p
Order By		USE TEMP B-TREE FOR ORDER BY
Full Scan	table: (subquery-3);	SCAN (subquery-3)
Full Scan	table: t;	SCAN t
Order By		USE TEMP B-TREE FOR ORDER BY

---

zadanie	pkt
1	1
2	1
3	1
4	1
5	1
6	2
razem:	7