

Bazy danych w data science





Prowadzący:
dr Grzegorz Migut
gmigut@agh.edu.pl

O prowadzącym

- Dyrektor działu technicznego w firmie StatSoft Polska
- Od ponad 20 lat zajmuje się analityką danych
- Realizował projekty w obszarach
 - Biznesu
 - Przemysłu
 - Nauki
- Zainteresowania
 - Uczenie maszynowe
 - Modele klasyfikacyjne
 - Analizy wielowymiarowe



O prowadzącym

- Polecam książkę na temat modelowania
- Budowa modeli uczenia maszynowego
- Kroki, etapy, zadania



Laboratorium – kolumnowe bazy danych I

PostgreSQL vs ClickHouse

Eksploracja danych,
agregacje i pierwszy
benchmark



Po tych zajęciach macie umieć

- połączyć się z PostgreSQL i ClickHouse,
- wykonać podstawowe zapytania analityczne na tabeli events,
- porównać wyniki uzyskane w obu bazach,
- wykonać prosty benchmark zapytań,
- sformułować pierwszy wniosek: kiedy baza kolumnowa ma przewagę



Co to są bazy kolumnowe

- Bazy kolumnowe przechowują dane kolumnami, a nie wierszami
- Są projektowane do analizy dużych zbiorów danych
- Szczególnie dobrze sprawdzają się w zadaniach takich jak:
 - SUM, COUNT, AVG,
 - GROUP BY,
 - analizy historyczne,
 - raportowanie



Co to są bazy kolumnowe

- Bazy kolumnowe przechowują dane kolumnami, a nie wierszami
- Są projektowane do analizy dużych zbiorów danych
- Typowe pytania analityczne:
 - Jak zmieniała się sprzedaż w czasie?
 - Ile było zdarzeń w każdym dniu?
 - Jak wyglądał ruch użytkowników według kraju i urządzenia?



Co to są kolumnowe bazy danych

- Typowe zastosowania:

- raporty
- hurtownie danych
- analityka biznesowa

- Narzędzia

- ClickHouse
- BigQuery
- Snowflake
- ...

- Różne narzędzia – ta sama idea: kolumny + agregacje



Dlaczego ClickHouse

- Kolumnowa baza danych zaprojektowana od początku pod analitykę
- Dobrze radzi sobie z
 - danymi zdarzeniowymi (eventy, logi, kliknięcia)
 - analizą historyczną
 - raportowaniem i KPI
- Skalowalny
 - od laptopa
 - do klastrów produkcyjnych



Dlaczego ClickHouse

- Szybki do agregacji i grupowania
- Darmowy i open-source
- Używany w praktyce (systemy analityczne, monitoring, BI)



- **UWAGA!** ClickHouse nie zastępuje wszystkiego!
PostgreSQL lepiej nadaje się do wielu zadań operacyjnych i transakcyjnych.



Wierszowe vs kolumnowe

- Bazy wierszowe:
 - szybkie dla pojedynczych rekordów
 - transakcje, UPDATE, INSERT
- Bazy kolumnowe:
 - szybkie dla dużych skanów
 - agregacje i raporty
- **Różne narzędzia do różnych zastosowań**



Ten sam SQL $\neq$ ten sam czas wykonania

- SQL często wygląda identycznie lub niemal identycznie
- Logika zapytania ta sama
- Różnica jest „pod spodem”
 - sposób przechowywania danych
 - sposób czytania danych
 - sposób liczenia agregacji
- Czas wykonania może różnić się o rząd wielkości



Ten sam SQL $\neq$ ten sam czas wykonania

- Zapytania analityczne (GROUP BYSUM, COUNT, AVG percentile) zwykle potrzebują kilku kolumn
- Baza wierszowa:
 - czyta całe wiersze
 - nawet kolumny, których nie używamy
- Skutek:
 - dużo I/O
 - dużo pamięci
 - wolniejsze agregacje



Prosty przykład

- Załóżmy, że mamy tabelę events z kolumnami:
 - event_time
 - event_type
 - user_id
 - session_id
 - country
 - device
 - price
 - quantity



Prosty przykład

- Załóżmy, że mamy tabelę events z kolumnami:
 - event_time
 - event_type
 - user_id
 - session_id
 - country
 - device
 - price
 - quantity

```
SELECT
    country,
    SUM(price * quantity) AS revenue
FROM events
WHERE event_type = 'purchase'
GROUP BY country;
```



Prosty przykład

- Baza wierszowa
 - Czyta wszystkie kolumny
- Baza kolumnowa
 - Zapytanie czyta tylko potrzebne kolumny
 - Reszta danych nie jest w ogóle ładowana



Laboratorium – kolumnowe bazy danych

Co będziemy robić?



Co będziemy robić na laboratorium

- Będziemy pracować na jednej tabeli events - 1 mln rekordów
- Dane dotyczące zdarzeń
 - czas zdarzenia
 - typ zdarzenia
 - użytkownik
 - sesja
 - kraj
 - urządzenie
 - cena
 - liczba sztuk



Co będziemy robić na laboratorium

- podstawową eksplorację danych,
- proste agregacje,
- pierwsze KPI sprzedażowe,
- porównanie wyników w PostgreSQL i ClickHouse,
- prosty benchmark zapytań



Robienie benchmarku

- Dla wybranego zapytania:
 - uruchamiamy je w PostgreSQL i w ClickHouse,
 - wykonujemy 4 uruchomienia w każdej bazie,
 - pierwszy pomiar odrzucamy jako rozgrzewkowy,
 - zapisujemy 3 kolejne czasy,
 - podajemy średni czas wykonania
- Ważne: nie benchmarkujemy zapytań zwracających bardzo duży wynik bez LIMIT
- DataGrip patrzymy przede wszystkim na execution time, fetching traktujemy pomocniczo




Plan pracy na dzisiaj

- Uruchomienie środowiska Docker
- Połączenie z PostgreSQL i ClickHouse
- Poznanie tabeli events
- Profil danych i aktywność w czasie
- Podstawowe KPI zakupowe
- Prosty benchmark: PostgreSQL vs ClickHouse
- Cel końcowy: skąd bierze się różnica czasu wykonania?



Ważny krok

- Połącz się z bazami za pomocą DBeaver lub DataGrip
- Baza: ds_lab
- Login: student
- Hasło: student
- **Uwaga** na zmianę portu dla połączeniu do postgresa
- **15432**



Connect to a database

Connection Settings
PostgreSQL connection settings

PostgreSQL

Main Advanced Driver properties + SSH, SSL, ... No profile

Server

Connect by: ☒ Host ☐ URL

URL: jdbc:postgresql://localhost:15432/ds_lab

Host: localhost Port: 15432

Database: ds_lab ☐ Show all databases

Authentication

Authentication: Database Native

Username: student

Password: Save password

[Connection variables information](#) [PostgreSQL](#) Connection details (name, type, ...)

Driver name: PostgreSQL Driver Settings Driver license

Test Connection ... < Back Next > Finish Cancel

Pytanie na start

- Czy te same zapytania w dwóch bazach zawsze powinny działać podobnie szybko?
- **Robocze hipotezy badawcze**
 - dla prostych zapytań różnica może być mała,
 - dla bardziej złożonych agregacji ClickHouse może mieć wyraźną przewagę



Powodzenia!