

# Laboratorium – kolumnowe bazy danych II

PostgreSQL vs ClickHouse

Zaawansowana analityka i  
wydajność



# Co dziś robimy?

- Lejek konwersji (*funnel*)
- Funkcje okna (ranking, trend)
- Segmentacja użytkowników (RFM)
- Benchmark i wnioski końcowe



# Zasady pracy

- To samo środowisko i tabela events co w Lab I
- ClickHouse = baza wiodąca
- PostgreSQL = tylko w benchmarku (zadanie 4)
- Ściąga: `sql_postgresql_clickhouse_sciaga.pdf`
- Oceniane są interpretacja i komentarz, nie sam fakt uruchomienia zapytania



# Która baza w którym zadaniu?

| Zadanie                | Baza                          |
|------------------------|-------------------------------|
| 0. Gotowość            | obie - sprawdzasz środowisko  |
| 1. Lejek konwersji     | ClickHouse                    |
| 2. Funkcje okna        | do wyboru                     |
| 3. Segmentacja RFM     | do wyboru (ClickHouse lepiej) |
| 4. Benchmark i wnioski | obie - porównanie obowiązkowe |



# Kluczowe różnice składowe

| Temat               | PostgreSQL                                       | ClickHouse                                         |
|---------------------|--------------------------------------------------|----------------------------------------------------|
| Zliczanie warunkowe | <code>CASE WHEN ... THEN<br/>1 ELSE 0 END</code> | <code>countIf(...)</code>                          |
| Suma warunkowa      | <code>SUM(CASE WHEN ...)</code>                  | <code>sumIf(value,<br/>condition)</code>           |
| Unikalne wartości   | <code>COUNT(DISTINCT x)</code>                   | <code>uniqExact(x)</code>                          |
| Data z timestampa   | <code>DATE(event_time)</code>                    | <code>toDate(event_time)</code>                    |
| Różnica dat         | <code>DATE_PART('day',<br/>t1 - t2)</code>       | <code>dateDiff('day',<br/>t2, t1)</code>           |
| Poprzednia wartość  | <code>LAG(x) OVER (...)</code>                   | <code>lagInFrame(x) OVER<br/>(... ROWS ...)</code> |

- Reszta w ściądze !!!





# Zadanie 1: Lejek konwersji (Funnel)

- Dla każdej sesji: czy był view, cart, purchase?
  - Policzyć liczbę sesji na każdym etapie
  - Obliczyć współczynniki przejścia: cart/view, purchase/cart, purchase/view
  - Powtórzyć w podziale na device
  - Użyć countIf zamiast CASE WHEN
- 
- W komentarzu: gdzie największy spadek? Czy device ma znaczenie?



## Zadanie 2: Funkcje okna (ranking i trend)

- Policzyć przychód per kraj, nadać ranking (RANK / DENSE\_RANK)
  - Policzyć dzienny przychód z zakupów
  - Dodać sumę narastającą (SUM OVER)
  - Dodać przychód z poprzedniego dnia (LAG / lagInFrame)
  - Obliczyć zmianę procentową
- 
- Wskazówka: najpierw CTE z GROUP BY day, potem funkcje okna



## Zadanie 3: Segmentacja RFM

- Każdy użytkownik opisany przez trzy liczby
  - Recency – jak dawno kupił
  - Frequency – ile razy kupił
  - Monetary – ile wydał
- Na tej podstawie dzielimy klientów na segmenty.





## Zadanie 3: Segmentacja RFM

- Policzyć R, F, M dla każdego użytkownika
- Sprawdzić rozkład danych (MIN, MAX, AVG)
- Samodzielnie dobrać progi i podzielić na segmenty: premium / standard / okazjonalny
- Dla każdego segmentu: liczba użytkowników, przychód, udział %
- W komentarzu: jak dobrałeś progi? Czy widać zasadę Pareto?



## Zadanie 4: Benchmark

- Zmierz czas wykonania trzech zapytań w obu bazach:
  - B1 - proste (wybrane z Lab I)
  - B2 - średnie (lejek z zadania 1)
  - B3 - złożone (okna lub RFM z zadania 2/3)
- Każde zapytanie 4 razy, pierwsze odrzuć, średnia z trzech kolejnych



## Zadanie 4: Benchmark

- Zanim zaczniesz benchmark
- SET use\_query\_cache = 0;
- Bez tego ClickHouse zwróci wynik z pamięci podręcznej zamiast policzyć od nowa.
- Pomiar 2-4 będą fałszywie szybkie
- Dodatkowo: dla B1 i B3 uruchom EXPLAIN ANALYZE (PostgreSQL) i EXPLAIN (ClickHouse).



# Zadanie 4: Benchmark

| Element                                   | Punkty    |
|-------------------------------------------|-----------|
| Zadanie 1 - lejek + komentarz o countIf   | 2         |
| Zadanie 2 - funkcje okna                  | 2         |
| Zadanie 3 - RFM z własnym dobozem progów  | 2         |
| Zadanie 4 - pomiary + tabela              | 1         |
| Zadanie 4 - analiza EXPLAIN               | 1         |
| Zadanie 4 - refleksja końcowa             | 1         |
| Jakość komentarzy we wszystkich zadaniach | 1         |
| <b>Razem</b>                              | <b>10</b> |



# Pytanie na koniec

- Gdybyś projektował system analityczny dla sklepu internetowego z milionami zdarzeń dziennie:
  - Co zostawiasz w PostgreSQL?
  - Co przenosisz do ClickHouse?
  - Dlaczego?





**Powodzenia!**